

**E2E Speedup
over FlashAttention**

—●— B200 —■— AWSv4 —◆— TPUv6e

